Laporan UTS *Big Data Analytic*:
Studi Kasus NYC TLC *Yellow Taxi Trip Records*,
Januari-Maret 2026



UNTAR
Universitas Tarumanagara

Disusun Oleh

Nama Lengkap	:	Callysta Elysia Theona Dethan
NIM	:	825240012
Mata Kuliah (Kelas)	:	Big Data Analytics (A)

Program Studi Sistem Informasi
Universitas Tarumanagara
Jakarta
2026

DAFTAR ISI

DAFTAR ISI ii
DAFTAR TABEL iv
DAFTAR GAMBAR 5
LATAR BELAKANG 6
Bab 1 Business Understanding & Big Data Context 7
1.1 Tujuan Analitik 7
1.2 Business questions 7
1.3 Karakteristik Big Data 8
1.4 Indikator analitik 8
BAB 2 DATA UNDERSTANDING, ARSITEKTUR, DAN TEKNOLOGI BIG DATA 9
2.1 Big Data Analytics Lifecycle (2a +2c) 9
2.2 Data Understanding (2b) 10
2.3 Arsitektur Konseptual (3a) 11
2.4 Akuisisi, Penggabungan, dan Jenis Data *(3b)* 12
2.5 Format Data dan Penyimpanan *(3c + 3d)* 12
2.6 Konsep Hadoop dan Apache Spark *(6a–c)* 13
BAB 3 DATA QUALITY DAN DATA PREPARATION 15
3.1 Data Profiling *(4a)* 15
3.2 Aturan Cleaning dan Hasilnya *(4b + 4c)* 17
3.3 Feature Engineering *(4d)* 17
BAB 4 EXPLORATORY DATA ANALYSIS 19
4.1 Statistik Deskriptif *(5a)* 19
4.2 Visualisasi dan Analisis Mendalam *(5b + 5c)* 20
4.2.1 Pola Waktu Perjalanan (BQ1) 20
4.2.2 Karakteristik Perjalanan (BQ2) 21
4.2.3 Pola Pembayaran (BQ3) 22
4.2.4 Lokasi dengan Aktivitas Tinggi (BQ4) 23
4.2.5 Faktor Tarif dan Tip (BQ5) 24
4.3 Analisis Korelasi *(5d)* 25
4.4 Ringkasan Insight *(5e)* 26
BAB 5 INSIGHT, REKOMENDASI, DAN KESIMPULAN 28
5.1 Insight Prioritas (7a) 28
5.2 Rekomendasi (7b) 29
5.3 Keterbatasan Dataset dan Analisis (7c) 30
5.4 Kesimpulan 30

DAFTAR PUSTAKA 31
LAMPIRAN 33
Lampiran A. Tabel Pendukung 33
Lampiran B. Kode Program (Notebook) 40
Lampiran C. AI Usage Declaration 41
Lampiran D. Individual Contribution Statement 42

DAFTAR TABEL

Tabel 1 Ringkasan Dataset Yellow Taxi Trip Record Januari-Maret 2026 6
Tabel 2 Business Question Yellow Taxi Trip Record Januari-Maret 2026 7
Tabel 3 Pemetaan Studi Kasus ke Big Data Analytics Lifecycle 9
Tabel 4 Ringkasan Data Understanding 10
Tabel 5 Rekapitulasi Tipe Data Atribut Dataset Yellow Taxi Trip Records 10
Tabel 6 Perbandingan Format Data CSV, JSON, Avro, dan Parquet 12
Tabel 7 Perbedaan RDD dan DataFrame 14
Tabel 8 Atribut dengan Nilai Kosong 15
Tabel 9 Hasil Nilai Duplikat, Nilai Nol, dan Nilai Tidak Logis 16
Tabel 10 Statistik Ringkas Atribut Numerik Sebelum Cleaning 16
Tabel 11 Jumlah Record Outlier Berdasarkan Batas Wajar 17
Tabel 12 Jumlah Record Sebelum dan Sesudah Cleaning 17
Tabel 13 Statistik Ringkas Fitur Numerik Setelah Cleaning 18
Tabel 14 Statistik Deskriptif Variabel Numerik 19
Tabel 15 Distribusi Variabel Kategorikal 20
Tabel 16 Proporsi Metode Pembayaran per Borough 22
Tabel 17 Perbandingan Karakteristik Perjalanan antar-Borough 23
Tabel 18 Median Tarif per Mil berdasarkan Kategori Jarak 25
Tabel 19 Ringkasan Insight Hasil Exploratory Data Analysis 26
Tabel 20 Insight Prioritas Hasil Analisis 28
Tabel 21 Rekomendasi bagi Manajemen Transportasi Kota 29
Tabel 22 Jumlah Nilai Kosong pada Seluruh Atribut 33
Tabel 23 Karakteristik Big Data pada Dataset 34
Tabel 24 Indikator Analitik 36
Tabel 25 Atribut yang Digunakan dan Perannya dalam Analisis 38
Tabel 26 Aturan Data Cleaning 39
Tabel 27 AI Usage Declaration 41
Tabel 28 Individual Contribution Statement 42

DAFTAR GAMBAR

Gambar 1 Diagram Arsitektur Konseptual 11
Gambar 2 Jumlah Perjalanan per Jam Penjemputan 21
Gambar 3 Rata-rata Jumlah Perjalanan per Hari 21
Gambar 4 Kepadatan Perjalanan berdasarkan Hari dan Jam 21
Gambar 5 Pola Perjalanan per Jam: Weekday vs Weekend 21
Gambar 6 Distribusi Jarak dan Durasi Perjalanan 22
Gambar 7 Proporsi Metode Pembayaran per Jam 22
Gambar 8 Proporsi Metode Pembayaran 22
Gambar 9 Sepuluh Zona Penjemputan dan Pengantaran Terpadat 23
Gambar 10 Persentase Perjalanan berdasarkan Borough Penjemputan 24
Gambar 11 Hubungan Jarak dan Tarif (Sampel 50.000 Perjalanan) 24
Gambar 12 Median Tarif per Mil berdasarkan Kategori Jarak 24
Gambar 13 Pola Tip per Metode Pembayaran dan per Jam 25
Gambar 14 Matriks Korelasi Variabel Numerik 26

LATAR BELAKANG

Taksi kuning merupakan salah satu moda transportasi publik penting di New York City karena dapat diakses langsung dari jalan dan beroperasi sepanjang hari, dengan 13.589 armada berizin hingga akhir tahun 2025 (NYC TLC, 2026a). Operasionalnya diatur oleh New York City Taxi and Limousine Commission (TLC), lembaga yang dibentuk pada tahun 1971 (NYC TLC, 2026a) untuk mengembangkan layanan transportasi *for-hire* di kota tersebut (NYC TLC, 2026b).

Setiap perjalanan taksi kuning dicatat dan dipublikasikan oleh TLC (NYC TLC, 2026b) melalui halaman TLC Trip Record Data, mencakup waktu, lokasi, jarak, dan rincian pembayaran. Tabel 1 menjelaskan bahwa periode Januari–Maret 2026, data mencapai 11.077.206 perjalanan dengan ukuran sekitar 181,9 MB dalam format Parquet. Volume ini melebihi kapasitas Microsoft Excel (1.048.576 baris per lembar kerja), sehingga pengolahan dilakukan menggunakan Python dan *library* Pandas (Candra, 2025) di Google Colab.

Data tersebut dapat dimanfaatkan manajemen transportasi kota untuk memahami pola permintaan, karakteristik perjalanan, pola pembayaran, lokasi dengan aktivitas tinggi, serta faktor yang berkaitan dengan tarif dan tip, misalnya untuk menyesuaikan jumlah dan penempatan armada. Namun, data masih berupa data mentah sehingga perlu dibersihkan dan dianalisis terlebih dahulu. Oleh karena itu, laporan ini disusun dengan peran sebagai tim *data analytics* untuk mengolah data Yellow Taxi Trip Records dan Taxi Zone Lookup menjadi *insight* yang mendukung keputusan operasional, melalui tahapan pemahaman bisnis, pemahaman data, pembersihan data, analisis eksploratif (EDA), serta penyusunan rekomendasi yang dapat ditelusuri kembali ke *business question*, data, dan hasil analisis.

Tabel 1 Ringkasan Dataset Yellow Taxi Trip Record Januari-Maret 2026

Bulan	Jumlah record	Jumlah atribut	Ukuran file	Tanggal akses
Januari 2026	3.724.889	20	61,19 MB	28 September 2026
Februari 2026	3.399.866	20	55,96 MB	28 September 2026
Maret 2026	3.952.451	20	64,75 MB	28 September 2026
Total	**11.077.206**	20	**181,9 MB**	

Sumber: (NYC TLC, 2026b), diolah penulis

Bab 1
Business Understanding & Big Data Context

1.1 Tujuan Analitik

Tujuan analitik studi kasus ini adalah menganalisis data perjalanan taksi kuning periode Januari–Maret 2026 untuk menghasilkan *insight* yang mendukung keputusan operasional. Secara khusus, analisis bertujuan untuk (1) mengidentifikasi pola permintaan berdasarkan jam dan hari; (2) menganalisis karakteristik perjalanan berdasarkan jarak, durasi, dan jumlah penumpang; (3) mengidentifikasi pola pembayaran berdasarkan metode, waktu, dan lokasi; (4) menentukan zona dan *borough* dengan aktivitas penjemputan dan pengantaran tertinggi; serta (5) menganalisis faktor yang berkaitan dengan tarif dan tip. Hasilnya diharapkan menjadi dasar keputusan terkait pengaturan armada pada jam sibuk, evaluasi kebijakan tarif, dan peningkatan layanan pembayaran.

1.2 Business questions

Berdasarkan tujuan analitik pada subbab 1.1, dirumuskan lima *business question* yang menjadi arah analisis dataset *Yellow Taxi Trip Record* Januari-Maret 2026. Setiap pertanyaan disusun secara spesifik, terukur (berupa angka atau perbandingan), terjawab dengan dataset, terbatas dalam periode Januari-Maret 2026, dan relevan dengan kebutuhan manajemen. Setiap pertanyaan diberi kode BQ1-BQ5 agar dapat dirujuk kembali pada tahap analisis dan rekomendasi. Daftar *business question* beserta atribut data yang digunakan ditampilkan melalui **Tabel 2.**

Tabel 2 *Business Question Yellow Taxi Trip Record* Januari-Maret 2026

Kode	**Business Question**	**Data yang digunakan**
BQ1	Pada jam dan hari apa jumlah perjalanan taksi kuning paling tinggi selama Januari–Maret 2026?	tpep_pickup_datetime
BQ2	Bagaimana karakteristik perjalanan berdasarkan jarak tempuh, durasi perjalanan, dan jumlah penumpang selama Januari-Maret 2026?	trip_distance, passenger_count, tpep_pickup_datetime dan tpep_dropoff_datetime (diolah menjadi durasi)
BQ3	Metode pembayaran apa yang paling sering digunakan, dan apakah berbeda berdasarkan waktu dan lokasi selama Januari-Maret 2026?	payment_type, tpep_pickup_datetime, PULocationID + Taxi Zone Lookup (Borough)
BQ4	Zona dan borough mana yang memiliki jumlah perjalanan tinggi berdasarkan penjemputan dan pengantaran selama Januari-Maret 2026?	PULocationID, DOLocationID + Taxi Zone Lookup (Zone, Borough)

BQ5	Apakah nilai tarif dan tip, berhubungan dengan jarak tempuh, waktu perjalanan, dan metode pembayaran selama Januari-Maret 2026?	fare_amount, tip_amount, trip_distance, durasi, tpep_pickup_datetime, payment_type

1.3 Karakteristik Big Data

Big Data umumnya dicirikan oleh beberapa karakteristik yang dikenal sebagai 5V atau dalam beberapa kasus tertentu dapat diperluas menjadi 7V. Karakteristik Big Data tersebut adalah Volume, Velocity, Variety, Veracity, dan Value. Pada model 7V, ditambahkan dua karakteristik lain, yaitu Variability atau perubahan konsistensi atau pola aliran data yang sering berfluktuasi, dan Visualization atau kemampuan menyajikan data yang kompleks ke dalam bentuk visual (Sivarajah et al., 2017). Kaitan setiap karakteristik dengan kondisi nyata dataset Yellow Taxi Trip Records periode Januari-Maret 2026 ditampilkan pada *Tabel 23*.

Berdasarkan karakteristik tersebut, dataset ini memerlukan alat bantu yang mampu mengolah data berukuran besar, yaitu Python dengan *library* Pandas, serta tahap *data profiling* dan pembersihan data (*data cleaning*) untuk memastikan kualitas data sebelum analisis dilakukan.

1.4 Indikator analitik

Indikator analitik merupakan ukuran kuantitatif yang digunakan untuk membantu pengelola mengambil keputusan bisnis. Indikator dalam laporan ini diturunkan dari *business question* 1 sampai 5 dengan total sepuluh indikator analitik. Daftar indikator beserta cara menghitung, *business question* yang dijawab, dan kegunaannya bagi pengelola transportasi ditampilkan pada *Tabel 24*.

BAB 2
DATA UNDERSTANDING, ARSITEKTUR, DAN TEKNOLOGI BIG DATA

2.1 Big Data Analytics Lifecycle (2a +2c)

Analisis data Yellow Taxi Trip Records periode Januari–Maret 2026 dalam laporan ini disusun mengikuti Big Data Analytics Lifecycle (Martinez et al., 2021), yang terdiri dari enam fase, yaitu Discovery, Data Preparation, Model Planning, Model Building, Communicate Results, dan Operationalize (Martinez et al., 2021). Tujuan analisis dalam laporan ini bersifat deskriptif dan eksploratif, sehingga fase Model Planning dan Model Building tidak menghasilkan model prediktif. Kedua fase tersebut diwujudkan dalam bentuk perencanaan dan pelaksanaan analisis statistik deskriptif, visualisasi, dan analisis korelasi. Penerapan setiap fase dijelaskan pada *Tabel 3*.

Tabel 3 Pemetaan Studi Kasus ke Big Data Analytics Lifecycle

Fase	Kegiatan pada studi kasus
Discovery / Business Understanding	Memahami konteks layanan taksi kuning NYC, menetapkan peran sebagai tim data analytics untuk manajemen transportasi kota, merumuskan tujuan analitik, BQ1–BQ5, sepuluh indikator analitik, serta mengidentifikasi karakteristik big data pada dataset
Data Preparation	Mengunduh data Januari–Maret 2026 dalam format Parquet dan Taxi Zone Lookup dalam format CSV, menggabungkan ketiga bulan dan melakukan join berdasarkan LocationID, memahami struktur atribut, melakukan data profiling (missing value, duplikat, nilai tidak logis, outlier), membersihkan data, dan membentuk atribut baru seperti durasi, jam, hari, dan kecepatan
Model Planning	Menentukan teknik analisis untuk setiap BQ, yaitu agregasi jumlah perjalanan, statistik deskriptif, persentase, dan korelasi Pearson, serta memilih alat yang sesuai dengan volume data, yaitu Python dan Pandas di Google Colab
Model Building	Menjalankan analisis yang telah direncanakan: menghitung indikator analitik, menyusun statistik deskriptif, membuat visualisasi, dan menghitung koefisien korelasi antara jarak, durasi, tarif, dan tip
Communicate Results	Menyusun insight prioritas yang menjawab BQ1–BQ5, menyampaikan rekomendasi kepada manajemen transportasi kota, serta menjelaskan keterbatasan dataset dan analisis

Operationalize	Mengusulkan penerapan hasil analisis, seperti penyesuaian jumlah armada pada jam sibuk dan zona padat, serta menjadikan proses pengolahan data sebagai alur batch yang dapat dijalankan ulang setiap kali TLC merilis data bulan baru

2.2 Data Understanding (2b)

Data understanding adalah tahap untuk mengenali data sebelum diolah lebih lanjut, meliputi pengumpulan, pendeskripsian, dan eksplorasi data (Sastya & Nugraha, 2023). Tahap ini bertujuan mengetahui struktur, isi, dan kualitas data serta memastikan data dapat menjawab *business question*. Pada laporan ini, *data understanding* dilakukan terhadap dataset Yellow Taxi Trip Records periode Januari–Maret 2026 dan Taxi Zone Lookup, meliputi identifikasi jumlah *record* dan atribut, tipe data, serta keterkaitan atribut dengan BQ1–BQ5.

Berdasarkan *Tabel 4* dan *Tabel 5* sebagian besar atribut bertipe *float* (13 dari 20 atribut) karena berisi nilai uang dan jarak yang membutuhkan angka desimal. Atribut passenger_count dan RatecodeID seharusnya berupa bilangan bulat, tetapi tersimpan sebagai *float* karena terdapat 3.057.123 *record* bernilai kosong pada perjalanan Flex Fare. Selain itu, atribut payment_type, PULocationID, dan DOLocationID bertipe *integer* tetapi sebenarnya merupakan kode kategori. Oleh karena itu, PULocationID dan DOLocationID digabungkan dengan LocationID pada Taxi Zone Lookup untuk memperoleh nama zona dan *borough*, sedangkan kode payment_type diterjemahkan menggunakan Data Dictionary.

Tabel 4 Ringkasan Data Understanding

Aspek	Isi
Unit analisis	1 baris = 1 transaksi perjalanan taksi kuning
Jumlah record	11.077.206
Jumlah atribut	20
Rentang waktu	*Pickup* paling awal: 31 Desember 2008, 23:03:20 *Pickup* paling akhir: 1 April 2026, 00:06:25
Tipe data	datetime (2), integer (4), float (13), teks (1)

Tabel 5 Rekapitulasi Tipe Data Atribut Dataset Yellow Taxi Trip Records

Tipe data (Pandas)	Arti	Jumlah	Atribut
datetime64	Tanggal dan waktu	2	tpep_pickup_datetime, tpep_dropoff_datetime

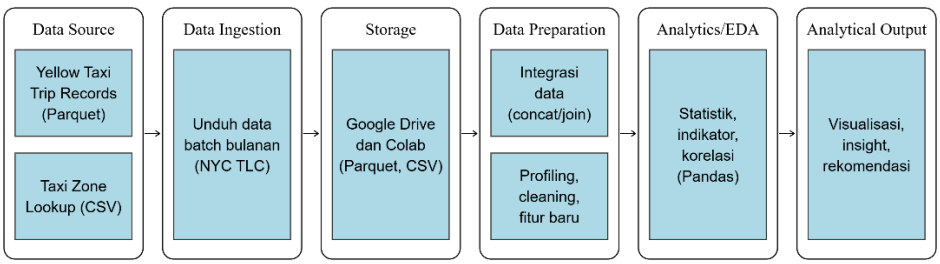
int32 / int64	Bilangan bulat	4	VendorID, PULocationID, DOLocationID, payment_type
float64	Bilangan desimal	13	passenger_count, trip_distance, RatecodeID, fare_amount, extra, mta_tax, tip_amount, tolls_amount, improvement_surcharge, total_amount, congestion_surcharge, Airport_fee, cbd_congestion_fee
object	Teks	1	store_and_fwd_flag
Total		20	

Dari 20 atribut yang tersedia, dipilih 10 atribut yang paling relevan untuk menjawab BQ1-BQ5. Atribut beserta deskripsi dan perannya dalam analisis ditampilkan pada *Tabel 25*. Pemilihan atribut didasarkan pada *business question,* yaitu atribut yang tercantum pada data yang digunakan di **Tabel 2**. Atribut lainnya tidak digunakan karena berisi biaya tambahan dan informasi teknis yang tidak relevan dengan *business question.*

2.3 Arsitektur Konseptual (3a)

Arsitektur big data umumnya tersusun atas beberapa komponen yang saling terhubung, mulai dari sumber data, penyimpanan, pemrosesan, hingga analitik (Oussous et al., 2018). Arsitektur konseptual pemrosesan big data pada studi kasus ini terdiri dari enam komponen yang membentuk alur pemrosesan berurutan, seperti ditampilkan pada *Gambar 1*. *Data Source* mencakup dua sumber data, yaitu *Yellow Taxi Trip Records* periode Januari–Maret 2026 dalam format Parquet dan *Taxi Zone Lookup* dalam format CSV. Pada tahap *Data Ingestion*, data diunduh secara *batch* per bulan dari halaman *TLC Trip Record Data* sesuai jadwal rilis TLC. Data tersebut kemudian disimpan pada *Storage* berupa Google Drive yang terhubung dengan Google Colab. Selanjutnya, tahap *Data Preparation* melakukan integrasi data, yaitu penggabungan data tiga bulan dan *join* dengan *Taxi Zone Lookup* berdasarkan *LocationID*, serta *data profiling*, pembersihan data, dan pembentukan fitur baru. Tahap *Analytics/EDA* menghitung statistik deskriptif, indikator analitik, dan korelasi menggunakan Python dan Pandas untuk menjawab BQ1–BQ5. Tahap terakhir, *Analytical Output*, menyajikan hasil analisis dalam bentuk visualisasi, *insight*, dan rekomendasi operasional bagi manajemen transportasi kota.

Gambar 1 Diagram Arsitektur Konseptual



2.4 Akuisisi, Penggabungan, dan Jenis Data *(3b)*

Proses akuisisi data dilakukan secara *batch* dengan mengunduh file transaksi bulanan langsung dari portal resmi NYC TLC per tanggal 28 September 2026. Penggabungan data dilakukan dalam dua tahapan, yaitu penggabungan vertikal (*concatenation*) untuk menyatukan dataset bulan Januari (3,72 juta), Februari (3,40 juta), dan Maret 2026 (3,95 juta) menjadi satu DataFrame berukuran 11.077.206 baris, serta penggabungan horizontal (*left join*) antara dataset transaksi dengan tabel *Taxi Zone Lookup* menggunakan atribut PULocationID dan DOLocationID ke LocationID untuk memetakan ID lokasi menjadi nama zona dan borough yang komunikatif. Seluruh data yang diolah tergolong sebagai data terstruktur (*structured data*) yang terdiri dari variabel angka, waktu, dan kategori.

2.5 Format Data dan Penyimpanan *(3c + 3d)*

Dataset transaksi taksi disimpan dalam format Apache Parquet yang berbasis kolom (*columnar storage*) dengan kompresi tinggi, sehingga 11.077.206 transaksi hanya berukuran sekitar 181,9 MB. Format ini juga memungkinkan pembacaan kolom tertentu saja (Belov & Nikulchev, 2021), sehingga pada laporan ini cukup 10 dari 20 atribut yang dimuat untuk menghemat memori. Data zona disimpan dalam format CSV yang berukuran ringan. Selama analisis, data dimuat sebagai DataFrame Pandas di Google Colab, sedangkan data mentah dan data hasil *cleaning* (df_clean.parquet) disimpan di Google Drive.

Berdasarkan *Tabel 6*, Parquet merupakan format yang paling sesuai karena agregasi pada atribut tertentu, seperti jarak, tarif, dan durasi, dapat dilakukan tanpa membaca seluruh baris. Selain itu, analisis bersifat *batch* (data dibaca berulang kali, bukan ditulis terus-menerus), sehingga Parquet lebih cocok dibandingkan Avro yang dirancang untuk *streaming*.

Untuk pengelolaan jangka panjang, arsitektur *Data Lakehouse* merupakan pilihan yang paling tepat karena menggabungkan fleksibilitas dan efisiensi biaya *Data Lake* dengan keandalan dan performa kueri *Data Warehouse* (Armbrust et al., 2021). File Parquet mentah yang dirilis TLC setiap bulan dapat disimpan sebagai lapisan *data lake* (Belov & Nikulchev, 2021), sedangkan data hasil *cleaning* (df_clean.parquet) berperan sebagai lapisan *data warehouse* yang siap dianalisis. Arsitektur ini sesuai untuk data yang diperbarui secara *batch* karena mampu menyimpan data historis yang terus bertambah dengan proses ETL (*Extract, Transform, Load*) yang lebih sederhana.

Tabel 6 Perbandingan Format Data CSV, JSON, Avro, dan Parquet

Sumber : diolah dari (Belov & Nikulchev, 2021)

Kriteria	CSV	JSON	Avro	Parquet

Model Penyimpanan	Berbasis Baris (*Row-based*)	Berbasis Baris (*Row-based*)	Berbasis Baris (*Row-based*)	Berbasis Kolom (*Columnar*)
Rasio Kompresi	Rendah (Teks Polos)	Rendah–Sedang	Tinggi	Sangat Tinggi
Kecepatan Kueri Kolom	Lambat (Scan Semua Baris)	Lambat (Scan Semua Baris)	Sedang	Sangat Cepat (*Column Subsetting*)
Penggunaan Utama	Pertukaran Data Sederhana	Data Semi-terstruktur / API	*Streaming Data Pipeline*	*Analytical Query / OLAP*

2.6 Konsep Hadoop dan Apache Spark *(6a–c)*

Apache Spark umumnya memproses data lebih cepat dibandingkan MapReduce karena memanfaatkan pemrosesan di memori (*in-memory*) (Ketu et al., 2020). Pengolahan data pada laporan ini dilakukan menggunakan Python dan Pandas di Google Colab karena volume data periode Januari–Maret 2026 masih dapat ditangani oleh satu mesin. Namun, data perjalanan taksi terus bertambah setiap bulan, sehingga untuk periode yang lebih panjang diperlukan teknologi pemrosesan terdistribusi seperti Apache Hadoop dan Apache Spark.

a. Fungsi HDFS, MapReduce, dan YARN dalam Ekosistem Hadoop

Hadoop terdiri dari tiga komponen utama. HDFS (Hadoop Distributed File System) berfungsi sebagai lapisan penyimpanan yang memecah file berukuran besar menjadi blok-blok dan menyimpannya secara terdistribusi di banyak node, dengan salinan (replikasi) di beberapa node agar data tidak hilang jika satu node rusak (Ketu et al., 2020). MapReduce berfungsi sebagai model pemrosesan paralel yang membagi pekerjaan menjadi dua tahap, yaitu Map untuk memproses data di setiap node dan Reduce untuk menggabungkan hasilnya (Dean & Ghemawat, 2008). YARN (Yet Another Resource Negotiator) berfungsi sebagai pengelola sumber daya cluster, seperti CPU dan memori, serta menjadwalkan pekerjaan yang berjalan di atasnya (Hedayati et al., 2023). YARN memisahkan pengelolaan sumber daya dari model

pemrograman, sehingga cluster Hadoop tidak hanya dapat menjalankan MapReduce, tetapi juga mesin pemrosesan lain seperti Spark.

b. Perbedaan RDD dan DataFrame pada Apache Spark

RDD (Resilient Distributed Dataset) adalah abstraksi data dasar pada Spark berupa kumpulan objek yang terdistribusi di banyak node dan dapat diproses secara paralel (Zaharia et al., 2016). DataFrame adalah abstraksi tingkat lebih tinggi yang menyimpan data dalam bentuk tabel dengan kolom bernama dan skema yang jelas, mirip tabel pada database atau DataFrame pada Pandas (Zaharia et al., 2016). Perbedaan utamanya ditampilkan pada *Tabel 7*.

Tabel 7 Perbedaan RDD dan DataFrame

Sumber : diolah dari (Zaharia et al., 2016)

Aspek	**RDD**	**DataFrame**
Struktur data	Kumpulan objek tanpa skema	Tabel dengan kolom bernama dan skema
Tingkat abstraksi	Rendah, pengguna menulis logika secara rinci	Tinggi, mirip operasi SQL
Optimasi	Tidak dioptimasi otomatis	Dioptimasi otomatis oleh Catalyst Optimizer
Kesesuaian	Data tidak terstruktur	Data terstruktur seperti data perjalanan taksi

c. Transformation, Action, dan Lazy Evaluation pada Spark

Transformation adalah operasi yang menghasilkan DataFrame atau RDD baru dari data yang sudah ada, tanpa langsung menjalankan perhitungan. Contohnya adalah filter(), misalnya df.filter(df.fare_amount > 0) untuk membuang perjalanan dengan tarif negatif atau nol. Action adalah operasi yang memicu perhitungan dan mengembalikan hasil ke pengguna atau menyimpannya ke penyimpanan. Contohnya adalah count() untuk menghitung jumlah perjalanan. Lazy evaluation adalah mekanisme Spark yang menunda eksekusi seluruh transformation sampai ada action yang dipanggil. Selama itu, Spark hanya mencatat urutan transformasi, lalu menyusun rencana eksekusi yang paling efisien saat action dijalankan (Zaharia et al., 2016).

BAB 3
DATA QUALITY DAN DATA PREPARATION

3.1 Data Profiling *(4a)*

Data *profiling* adalah proses menentukan metadata dari suatu dataset dan memahami struktur serta isi data (Naumann, 2013), menilai kualitas data seperti kelengkapan, keunikan, dan validitas, dan menjadi dasar proses data *cleansing* dan integrasi data, serta mendukung pemodelan data dan pengambilan keputusan yang lebih akurat. Hasil profiling ditampilkan pada *Tabel 8*, *Tabel 9*, *Tabel 10*, dan *Tabel 11*.

a. Missing Value

Missing value adalah hilangnya nilai suatu atribut yang dapat disebabkan oleh kesalahan pengumpulan data atau kesalahan input (Prasetya et al., 2023). Data yang hilang dapat menurunkan kualitas hasil analisis jika tidak ditangani dengan metode yang tepat (Widianti & Pratama, 2024). Berdasarkan *Tabel 8*, terdapat lima atribut yang memiliki nilai kosong dengan jumlah yang sama, yaitu 3.057.123 *record* (27,6%). Setelah ditelusuri, seluruh *record* tersebut memiliki payment_type = 0, yaitu perjalanan Flex Fare dengan tarif yang ditentukan di awal. Hal ini menunjukkan bahwa nilai kosong terjadi secara sistematis, bukan secara acak.

Tabel 8 Atribut dengan Nilai Kosong

Atribut	Jumlah nilai kosong	Persentase (%)
passenger_count	3.057.123	27,60
RatecodeID	3.057.123	27,60
store_and_fwd_flag	3.057.123	27,60
congestion_surcharge	3.057.123	27,60
Airport_fee	3.057.123	27,60

Sumber: NYC TLC (2026), diolah penulis, 15 atribut lainnya tidak memiliki nilai kosong

b. Duplikat dan Nilai Tidak Logis

Berdasarkan hasil profiling yang ditampilkan di *Tabel 9*, tidak ditemukan record duplikat. Namun, terdapat 10 record di luar periode Januari-Maret 2026, bahkan ada yang tercatat pada tahun 2008, dan durasi ada yang kurang dari atau sama dengan 0 menit sebanyak

134.801 record. Nilai negatif terdapat pada atribut fare_amount sebanyak 86.908 record, total_amount sebanyak 88.580 record, tip_amount sebanyak 148 record. Nilai negatif dan durasi kurang dari atau sama dengan nol menjadi masalah karena tidak mungkin durasi perjalanan dari penjemputan sampai tiba di tujuan adalah nol atau bahkan negatif, dan tarif tidak mungkin negatif karena diduga merupakan transaksi pembatalan atau pengembalian dana. Selain itu, terdapat nilai nol pada tarif sebanyak 7.456 data, jarak dengan nilai nol sebanyak 370.198 record, dan penumpang dengan nilai nol sebanyak 40.638 record. Masalah terbesar disini adalah nilai nol pada atribut jarak yaitu 370.198 record (3,34%).

Tabel 9 Hasil Nilai Duplikat, Nilai Nol, dan Nilai Tidak Logis

Jenis masalah	Pengecekan	Jumlah record	%
Duplikat	Baris identik	0	0,00
Waktu tidak logis	Pickup di luar Januari–Maret 2026	10	0,00
	Durasi ≤ 0 menit	134.801	1,22
Nilai negatif	Tarif (fare_amount) negatif	86.908	0,78
	Total bayar (total_amount) negatif	88.580	0,80
	Tip (tip_amount) negatif	148	0,00
Nilai nol	Tarif = 0	7.456	0,07
	Jarak = 0 mil	370.198	3,34
	Penumpang = 0	40.638	0,37

sumber : NYC TLC (2026), diolah penulis

c. Outlier

Tabel 10 dan *Tabel 11* menunjukkan adanya outlier ekstrem pada atribut jarak, durasi, dan tarif, yang terlihat dari nilai maksimum yang jauh melebihi persentil 99%. Pada atribut jarak, nilai maksimum mencapai 328.522,20mil, sedangkan 99% perjalanan berjarak dibawah 20 mil.Outlier tersebut membuat rata-rata jarak 6,22 mil jauh lebih besar dibandingkan median 1,80 mil, sehingga berdampak rata-rata.

Tabel 10 Statistik Ringkas Atribut Numerik Sebelum Cleaning

Statistik	Jarak (mil)	Durasi (menit)	Tarif (USD)
Rata-rata	6,22	17,43	21,25
Std. deviasi	620,71	25,09	18,74
Minimum	0,00	−186,67	−2.555,20
Persentil 1%	0,00	0,00	3,00
Median (50%)	1,80	13,53	15,60

Persentil 99%	19,51	73,23	81,19
Maksimum	328.522,20	9.265,15	2.555,20

Tabel 11 Jumlah Record Outlier Berdasarkan Batas Wajar

Pengecekan	Jumlah record	%	Pengecekan
Jarak > 100 mil	495	0,00	Jarak > 100 mil
Durasi > 180 menit	4.464	0,04	Durasi > 180 menit

3.2 Aturan Cleaning dan Hasilnya *(4b + 4c)*

Data cleaning adalah proses untuk meningkatkan kualitas data agar data siap digunakan pada tahap analisis, yang terdiri dari kegiatan mengidentifikasi, mendeteksi, dan memperbaiki kesalahan pada data (Ridzuan & Wan Zainon, 2019). Pada konteks big data, proses ini menjadi lebih kompleks dan memakan waktu karena jumlah data yang terus bertambah, sehingga banyak metode pembersihan data konvensional tidak lagi sesuai (Widianti & Pratama, 2024). Pada laporan ini, aturan data cleaning disusun berdasarkan hasil data profiling, meliputi penanganan missing value, nilai kosong, nilai tidak logis, dan outlier. Aturan cleaning beserta jumlah record terdampak, tindakan, dan alasannya ditampilkan pada *Tabel 26*, sedangkan jumlah record sebelum dan sesudah cleaning ditampilkan pada *Tabel 12*.

Tabel 12 Jumlah Record Sebelum dan Sesudah Cleaning

Keterangan	Jumlah *record*	Persentase (%)
Sebelum *cleaning*	11.077.206	100,00
Dihapus	624.413	5,64
Sesudah *cleaning*	10.452.793	94,36

3.3 Feature Engineering *(4d)*

Feature engineering adalah proses membentuk variabel baru dari data yang tersedia agar lebih informatif untuk analisis (Verdonck et al., 2024). *Feature engineering* dilakukan untuk membentuk variabel-variabel baru yang mendukung pemenuhan sepuluh indikator analitik serta menjawab BQ1–BQ5 secara komprehensif. Pembentukan fitur temporal mengekstrak informasi jam penjemputan, hari, dan kategori tipe hari (*weekday* vs *weekend*) untuk mengidentifikasi pola kepadatan waktu perjalanan.

Fitur durasi perjalanan dihitung dari selisih waktu penjemputan dan pengantaran, yang kemudian dikombinasikan dengan jarak tempuh untuk menghasilkan variabel kecepatan rata-rata guna mendeteksi kejanggalan operasional. Untuk menganalisis struktur biaya dan tingkat kepuasan penumpang, dibentuk variabel turunan berupa tarif per mil serta persentase tip. Terakhir, penggabungan dengan tabel referensi lokasi menghasilkan variabel wilayah baru berupa nama zona dan *borough* penjemputan maupun pengantaran untuk memetakan pemusatan aktivitas perjalanan di New York City. Statistik ringkas fitur numerik hasil *feature engineering* ditampilkan pada Tabel *13*, dengan median kecepatan 9,30 mil/jam dan median tarif per mil 7,65 USD.

Tabel 13 Statistik Ringkas Fitur Numerik Setelah Cleaning

Statistik	Jarak (mil)	Durasi (menit)	Kecepatan (mil/jam)	Tarif per mil (USD)	Persentase tip (%)
Jumlah data	10.452.793	10.452.793	10.452.793	10.452.793	6.711.607
Rata-rata	3,49	17,45	10,90	23,74	24,62
Std. deviasi	4,24	14,09	6,38	226,12	12,41
Minimum	0,01	1,00	0,00	0,00	0,00
Persentil 1%	0,22	2,38	1,90	3,14	0,00
Median (50%)	1,90	13,73	9,30	7,65	26,42
Persentil 99%	19,55	73,23	34,24	46,00	54,05
Maksimum	99,93	179,97	80,00	62370,00	100,00

BAB 4
EXPLORATORY DATA ANALYSIS

Exploratory Data Analysis (EDA) dilakukan terhadap 10.452.793 *record* hasil pembersihan data untuk mengeksplorasi karakteristik perjalanan, pola spasial dan temporal, serta hubungan antarvariabel guna menjawab BQ1–BQ5.

4.1 Statistik Deskriptif *(5a)*

Analisis statistik deskriptif memberikan gambaran umum mengenai distribusi data numerik dan kategorikal setelah pembersihan. Hasil ringkasan ukuran pemusatan dan sebaran data numerik (seperti jarak, durasi, tarif, kecepatan, dan tip) disajikan pada *Tabel 14*. Sementara itu, rincian proporsi distribusi untuk variabel kategorikal (seperti metode pembayaran, tipe hari, dan wilayah penjemputan) ditampilkan pada *Tabel 15*. Secara umum, data menunjukkan bahwa operasional taksi kuning didominasi oleh perjalanan rute pendek di wilayah Manhattan pada hari kerja dengan mayoritas transaksi menggunakan kartu kredit

Tabel 14 Statistik Deskriptif Variabel Numerik

Variabel	Jumlah data	Rata-rata	Median	Std. deviasi	Minimum	Maksimum
Jarak (mil)	10.452.793	3,49	1,90	4,24	0,01	99,93
Durasi (menit)	10.452.793	17,45	13,73	14,09	1,00	179,97
Jumlah penumpang	7.636.002	1,24	1,00	0,64	1,00	6,00
Tarif (USD)	10.452.793	21,35	15,60	17,33	0,01	950,00
Tip (USD)	10.452.793	2,76	2,00	3,82	0,00	766,00
Total bayar (USD)	10.452.793	30,07	23,55	20,92	0,00	951,00
Kecepatan (mil/jam)	10.452.793	10,90	9,30	6,38	0,00	80,00
Tarif per mil (USD)	10.452.793	23,74	7,65	226,12	0,00	62.370,00
Persentase tip (%)	6.711.607	24,62	26,42	12,41	0,00	100,00

Tabel 15 Distribusi Variabel Kategorikal

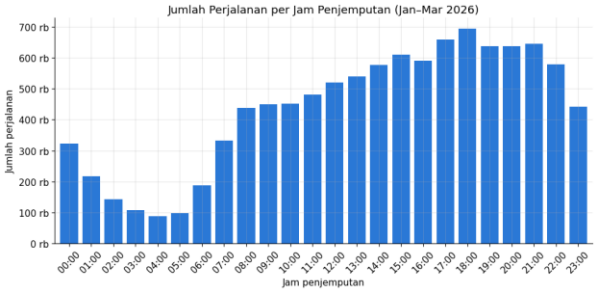
Variabel	Kategori	Jumlah	Persentase (%)
Metode pembayaran	Kartu kredit	6.721.026	64,30
	Flex Fare	2.778.321	26,58
	Tunai	872.067	8,34
	Sengketa	59.485	0,57
	Tanpa biaya	21.894	0,21
Tipe hari	Weekday	7.383.435	70,64
	Weekend	3.069.358	29,36
Borough penjemputan	Manhattan	8.972.903	85,84
	Queens	923.328	8,83
	Brooklyn	436.232	4,17
	Bronx	106.091	1,01
	Unknown	11.606	0,11
	Staten Island	1.177	0,01
	EWR	65	0,00

4.2 Visualisasi dan Analisis Mendalam *(5b + 5c)*

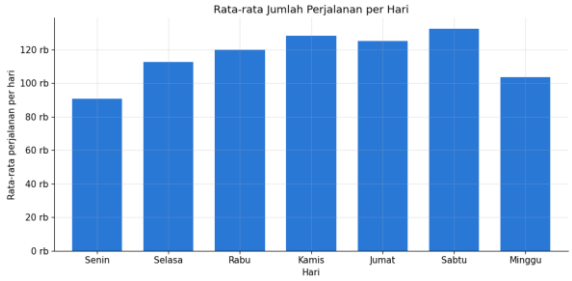
Visualisasi disusun berdasarkan BQ1–BQ5 untuk mengidentifikasi pola waktu, karakteristik perjalanan, pola pembayaran, lokasi aktivitas tinggi, dan faktor tarif. Tiga analisis mendalam difokuskan pada fluktuasi jam sibuk, pola pembayaran digital antarwilayah, serta penurunan tarif per mil berdasarkan kategori jarak.

4.2.1 Pola Waktu Perjalanan (BQ1)

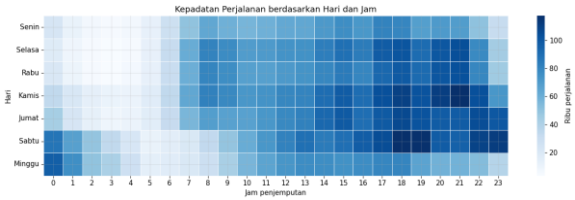
Sebagaimana ditunjukkan pada Gambar *2*, volume perjalanan terendah terjadi pukul 04:00 (±90 ribu) dan mencapai puncaknya pada pukul 18:00 (±695 ribu perjalanan). Pada Gambar *3* hari Sabtu mencatatkan rata-rata tertinggi (±132 ribu/hari), sedangkan Senin paling rendah (±91 ribu/hari). Kepadatan tertinggi pada Gambar *4* terkonsentrasi pada Kamis, Jumat, dan Sabtu malam (pukul 18:00–21:00). Sementara itu, Gambar *5* memperlihatkan rata-rata harian *weekend* yang lebih tinggi dibanding *weekday* (118.052 vs 115.366 perjalanan/hari) akibat lonjakan perjalanan pada pukul 00:00–04:00.



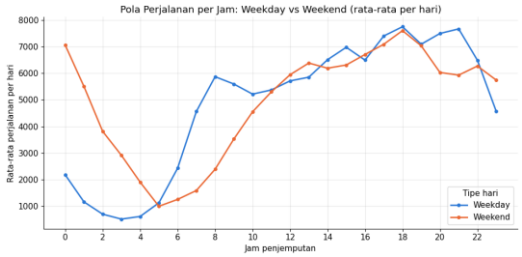
Gambar 2 Jumlah Perjalanan per Jam Penjemputan



Gambar 3 Rata-rata Jumlah Perjalanan per Hari



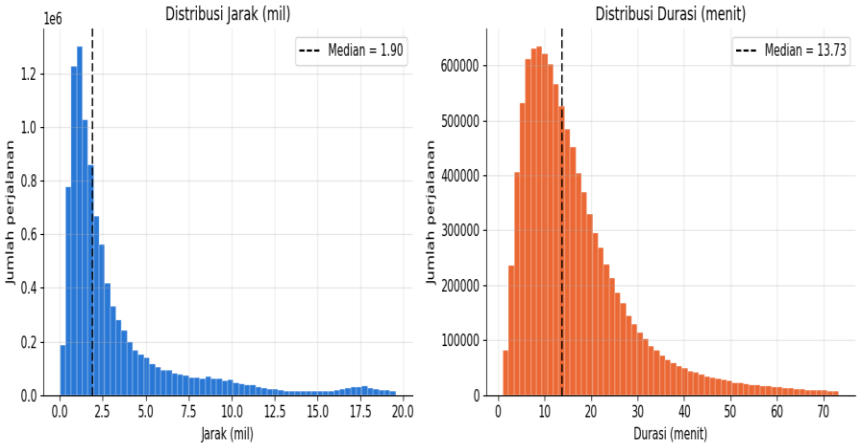
Gambar 4 Kepadatan Perjalanan berdasarkan Hari dan Jam



Gambar 5 Pola Perjalanan per Jam: Weekday vs Weekend

4.2.2 Karakteristik Perjalanan (BQ2)

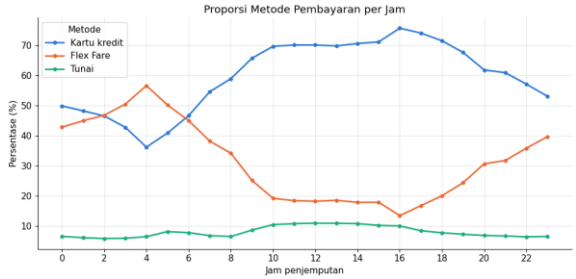
Distribusi jarak dan durasi pada Gambar 6 bersifat menceng ke kanan (right-skewed), dengan median jarak 1,90 mil dan durasi 13,73 menit, sedangkan rata-ratanya lebih tinggi (3,49 mil dan 17,45 menit) karena sebagian kecil perjalanan jauh. Median kecepatan hanya 9,30 mil/jam, yang menunjukkan kondisi lalu lintas yang padat. Sebanyak 83,21% perjalanan membawa satu penumpang, sehingga taksi kuning lebih banyak berperan sebagai transportasi perorangan.



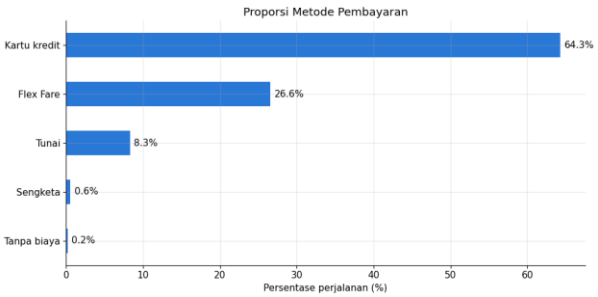
Gambar 6 Distribusi Jarak dan Durasi Perjalanan

4.2.3 Pola Pembayaran (BQ3)

Proporsi pembayaran pada *Gambar 7* dan *Gambar 8* didominasi kartu kredit (64,30%), *Flex Fare* (26,58%), dan tunai (8,34%). *Flex Fare* mencapai porsi tertinggi pada pukul 04:00–05:00 (>55%), sedangkan kartu kredit mendominasi jam aktif siang-sore hingga ±75%. Berdasarkan *Tabel 16*, *Flex Fare* menjadi metode utama di Brooklyn (65,3%) dan Staten Island (81,0%), sementara penggunaan tunai tertinggi berada di Queens (14,4%).



Gambar 7 Proporsi Metode Pembayaran per Jam



Gambar 8 Proporsi Metode Pembayaran

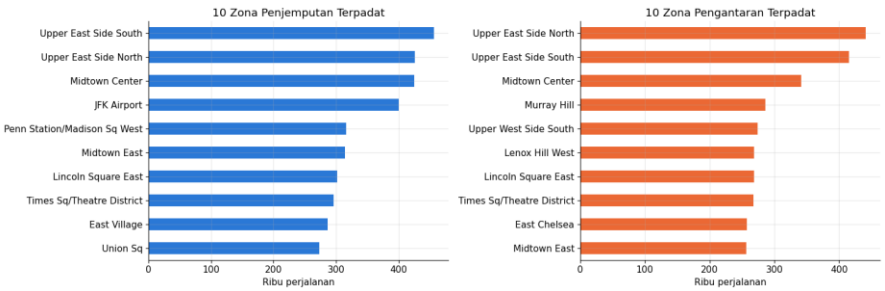
Tabel 16 Proporsi Metode Pembayaran per Borough

Borough	**Kartu kredit**	**Flex Fare**	**Tunai**

Manhattan	65,9	25,3	8,1
Queens	64,8	19,1	14,4
Brooklyn	33,3	65,3	1,3
Bronx	51,3	47,1	1,5
Staten Island	7,1	81,0	11,7

4.2.4 Lokasi dengan Aktivitas Tinggi (BQ4)

Berdasarkan *Gambar 9*, Upper East Side South (±457 ribu) dan Upper East Side North menjadi zona utama, dengan JFK Airport berada di peringkat ke-4 penjemputan. Sebagaimana terlihat pada *Gambar 10* dan *Tabel 17*, Manhattan mendominasi 85,84% penjemputan (median jarak 1,67 mil), sedangkan Queens mencatatkan rute terjauh (median 10,02 mil; tarif 44,30 USD). Median tip di Brooklyn, Bronx, dan Staten Island berada di angka 0%.



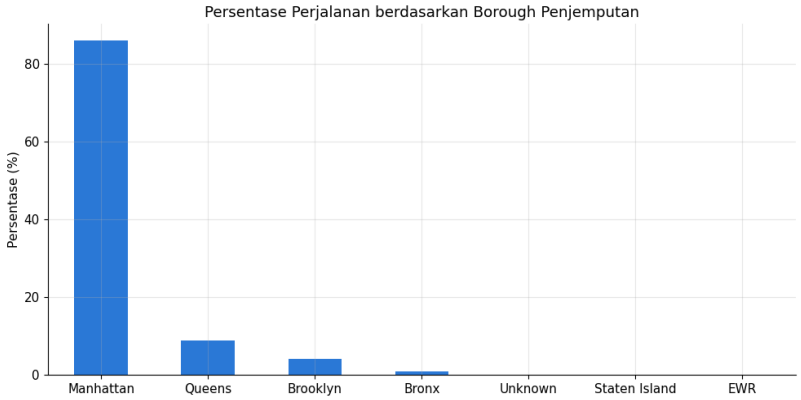
Gambar 9 Sepuluh Zona Penjemputan dan Pengantaran Terpadat

Tabel 17 Perbandingan Karakteristik Perjalanan antar-Borough

Keterangan Tabel : Unknown dan EWR tidak ditampilkan (0,11%).

Borough	**Perjalanan**	**%**	**Median jarak (mil)**	**Median tarif (USD)**	**Median tip (%)**
Manhattan	8.972.903	85,84	1,67	14,20	27,10
Queens	923.328	8,83	10,02	44,30	22,56
Brooklyn	436.232	4,17	4,40	28,50	0,00
Bronx	106.091	1,01	6,80	32,12	0,00

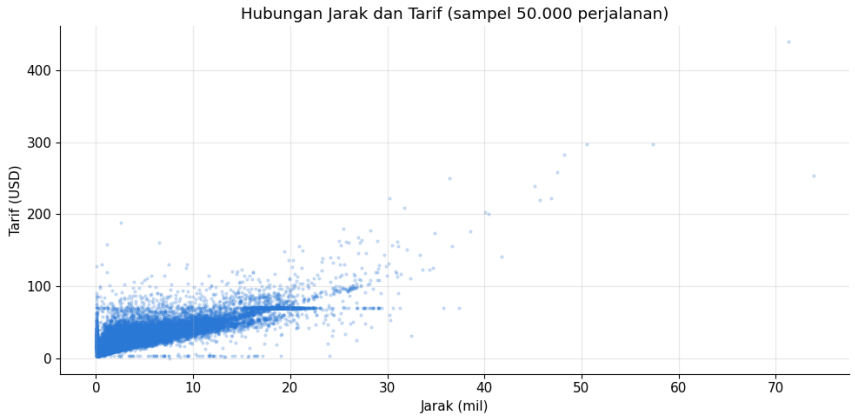
Staten Island	1.177	0,01	7,70	32,80	0,00



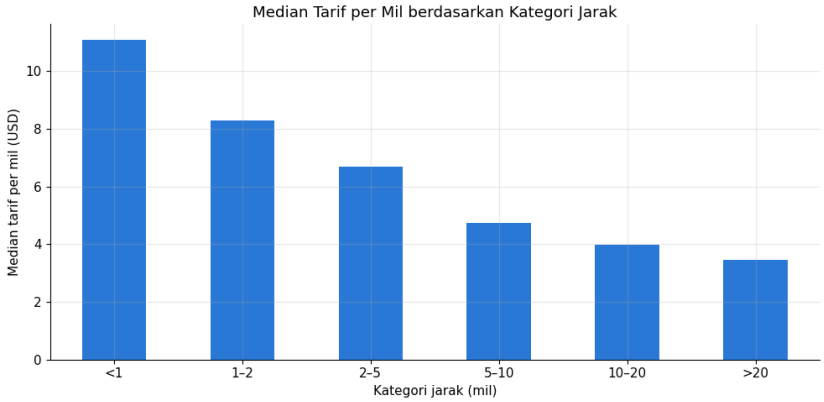
Gambar 10 Persentase Perjalanan berdasarkan Borough Penjemputan

4.2.5 Faktor Tarif dan Tip (BQ5)

Hubungan linier jarak dan tarif ditampilkan pada Gambar *11*, dengan konsentrasi titik pada tarif 70,00 USD (skema *flat fare* JFK–Manhattan). Gambar *12* dan Tabel 18 memperlihatkan penurunan median tarif per mil seiring bertambahnya jarak (11,07 USD/mil pada rute <1 mil vs 3,47 USD/mil pada rute >20 mil). Pada *Gambar 13*, rata-rata tip kartu kredit mencapai 4,12 USD (tunai tercatat 0,00 USD) dengan persentase tip tertinggi terjadi pukul 18:00–19:00 (>28%).



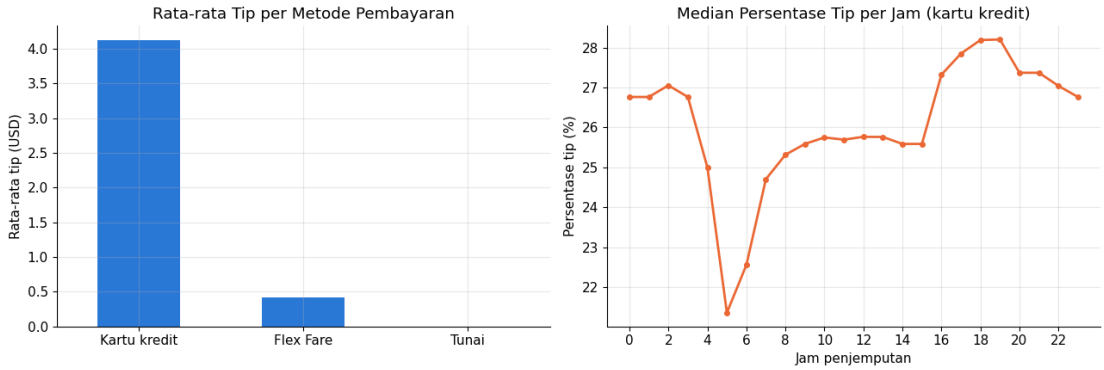
Gambar 11 Hubungan Jarak dan Tarif (Sampel 50.000 Perjalanan)



Gambar 12 Median Tarif per Mil berdasarkan Kategori Jarak

Tabel 18 Median Tarif per Mil berdasarkan Kategori Jarak

Kategori jarak (mil)	Median tarif per mil (USD)
< 1	11,07
1–2	8,28
2–5	6,69
5–10	4,74
10–20	3,99
> 20	3,47



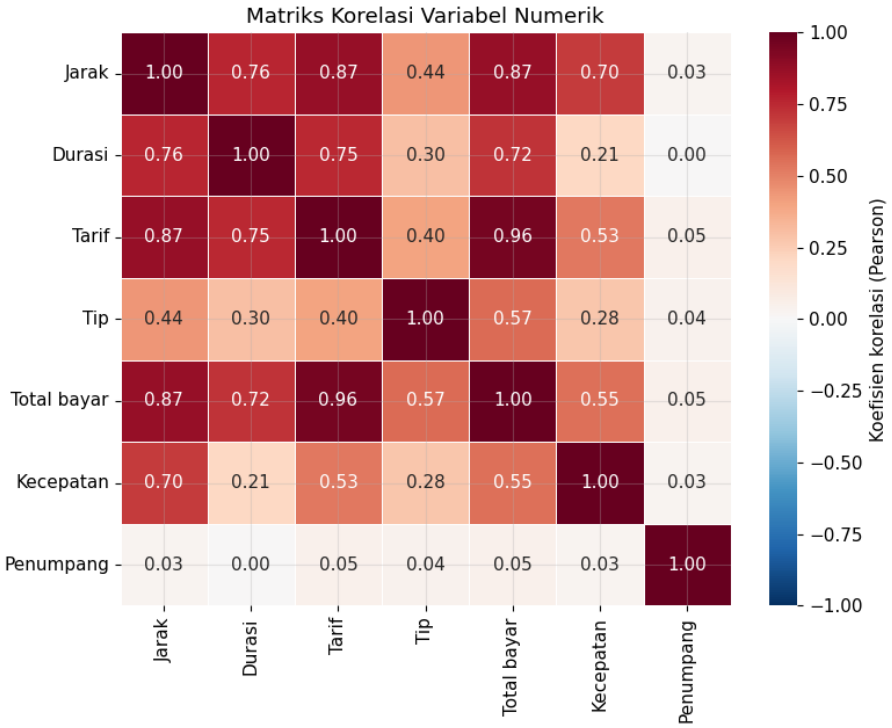
Gambar 13 Pola Tip per Metode Pembayaran dan per Jam

4.3 Analisis Korelasi *(5d)*

Kekuatan korelasi diinterpretasikan berdasarkan pedoman Mukaka (2012), yaitu 0,90–1,00 sangat kuat; 0,70–0,90 kuat; 0,50–0,70 sedang; 0,30–0,50 lemah; dan di bawah 0,30 dapat diabaikan (Mukaka, 2012). Sebagaimana ditunjukkan pada *Gambar 14*, tarif argo memiliki korelasi positif yang sangat kuat dengan total pembayaran (r = 0,96) serta jarak tempuh (r = 0,87). Durasi perjalanan juga menunjukkan korelasi kuat dengan jarak tempuh (r = 0,76) dan tarif (r = 0,75). Sementara itu, tip memiliki hubungan moderat dengan tarif (r = 0,40), sedangkan jumlah penumpang hampir tidak berkorelasi dengan variabel numerik lainnya ($r \approx$ 0,00–0,05). Nilai korelasi tip perlu ditafsirkan dengan hati-hati karena tip pada pembayaran tunai tidak tercatat dalam data, sehingga banyak perjalanan memiliki nilai tip nol meskipun penumpang mungkin memberikan tip secara langsung.

Meskipun demikian, korelasi tidak selalu menunjukkan hubungan sebab-akibat, karena korelasi hanya mengukur seberapa kuat dua variabel bergerak bersama. Contohnya, jarak berkorelasi kuat

dengan kecepatan (r = 0,70), tetapi jarak yang jauh tidak menyebabkan taksi melaju lebih cepat. Kemungkinan penyebabnya, perjalanan jauh umumnya melewati jalan tol atau rute menuju bandara yang lebih lancar, sehingga jenis rute menjadi variabel ketiga yang memengaruhi keduanya. Selain itu, korelasi tarif dengan total pembayaran (r = 0,96) tinggi karena total pembayaran memang dihitung dari tarif ditambah biaya lain. Oleh karena itu, hasil korelasi perlu ditafsirkan dengan hati-hati sebagai dasar pengambilan keputusan.



Gambar 14 Matriks Korelasi Variabel Numerik

4.4 Ringkasan Insight *(5e)*

Berdasarkan hasil eksplorasi data, dirumuskan tujuh *insight* yang masing-masing didukung bukti kuantitatif, sebagaimana ditampilkan pada *Tabel 19*. Secara umum, *insight* tersebut menunjukkan bahwa permintaan taksi memuncak pada sore hari kerja dan malam akhir pekan, perjalanan didominasi rute pendek dengan penumpang tunggal, serta aktivitas penjemputan terpusat di Manhattan dan Bandara JFK. Selain itu, Flex Fare menjadi metode pembayaran utama di Brooklyn dan Staten Island, sedangkan tarif berkorelasi sangat kuat dengan jarak tempuh.

Tabel 19 Ringkasan Insight Hasil Exploratory Data Analysis

BQ	***Insight***	**Bukti kuantitatif**	**Sumber**
BQ1	Puncak permintaan terjadi pada sore hari	Pukul 18:00: 693.915 perjalanan, ±7,8 kali pukul 04:00 (88.524)	Gambar *2*
BQ1	Akhir pekan sedikit lebih ramai per hari dibanding hari kerja	Rata-rata 118.052 (*weekend*) vs 115.366 (*weekday*) per hari; Sabtu tertinggi (132.371)	Gambar *3*, Gambar *5*

BQ2	Perjalanan didominasi rute pendek dan penumpang tunggal	Median 1,90 mil dan 13,73 menit; 83,21% satu penumpang	Gambar 6
BQ3	Kartu kredit dominan, tetapi Flex Fare unggul di Brooklyn dan Staten Island	Kartu kredit 64,30%; Flex Fare 65,3% di Brooklyn dan 81,0% di Staten Island	*Gambar 7*, *Tabel 16*
BQ4	Penjemputan terpusat di Manhattan, dengan JFK sebagai titik penting	Manhattan 85,84%; JFK peringkat ke-4 (400.458 penjemputan)	*Gambar 9*, *Tabel 17*
BQ5	Perjalanan pendek paling mahal per mil	< 1 mil: 11,07 USD/mil vs > 20 mil: 3,47 USD/mil (±3,2 kali); r jarak–tarif = 0,87	Gambar *12*, *Gambar 14*
BQ5	Tip kartu kredit tinggi, tetapi tidak merata antar wilayah	Rata-rata tip kartu kredit 4,12 USD; median tip 0% di Brooklyn, Bronx, dan Staten Island	*Gambar 13*, *Tabel 17*

BAB 5
INSIGHT, REKOMENDASI, DAN KESIMPULAN

5.1 Insight Prioritas (7a)

Berdasarkan hasil analisis eksploratif, dipilih lima *insight* prioritas yang diurutkan berdasarkan relevansinya terhadap keputusan operasional manajemen transportasi kota. Daftar *insight* ditampilkan pada *Tabel 20*.

Tabel 20 Insight Prioritas Hasil Analisis

Insight	Bukti kuantitatif	Sumber	Alasan prioritas
Permintaan tidak merata sepanjang waktu, dengan puncak pada sore hari kerja dan malam akhir pekan	Puncak pukul 18:00 (693.915 perjalanan); Sabtu rata-rata 132.371 perjalanan/hari	Gambar *2*, Gambar *3*, Gambar *4*	Langsung terkait dengan pengaturan jumlah armada harian dan penyesuaian jadwal kerja pengemudi pada jam sibuk (rush hour).
Aktivitas penjemputan terpusat di Manhattan dan bandara JFK	Manhattan 85,84%; Upper East Side South 456.975 penjemputan; JFK peringkat ke-4; median jarak Queens 10,02 mil	*Gambar 9*, *Gambar 10*, *Tabel 17*	Terkait langsung dengan penempatan pangkalan armada (taxi stand) dan efisiensi alokasi penjemputan di area padat penumpang.
Flex Fare menjadi metode utama di Brooklyn dan Staten Island	Flex Fare 65,3% di Brooklyn dan 81,0% di Staten Island, sedangkan secara keseluruhan 26,58%	*Gambar 8*, *Tabel 15*	Terkait dengan peningkatan kualitas layanan pembayaran digital dan pemerataan aksesibilitas taksi di wilayah suburban berbasis aplikasi.
Perjalanan didominasi rute pendek dan penumpang tunggal	Median jarak 1,90 mil; 83,21% membawa satu penumpang	Gambar 6	Terkait dengan evaluasi jenis atau spesifikasi armada taksi kota yang efisien untuk mobilitas perorangan jarak pendek.
Tarif per mil menurun seiring bertambahnya jarak, dan terdapat skema flat fare JFK	Median tarif per mil rute < 1 mil sebesar 11,07 USD vs > 20 mil sebesar 3,47 USD; konsentrasi tarif tetap ±70 USD untuk rute JFK	Gambar *11*, Gambar *12*, Tabel 18	Terkait dengan evaluasi kewajaran struktur tarif, terutama bagi penumpang perjalanan jarak pendek.

Urutan insight pada Tabel 20 ditentukan berdasarkan seberapa langsung insight tersebut dapat ditindaklanjuti oleh manajemen transportasi kota. Insight pola waktu (BQ1) ditempatkan pertama karena berkaitan langsung dengan pengaturan jumlah armada setiap hari. Insight berikutnya, yaitu pemusatan lokasi (BQ4) dan pola pembayaran Flex Fare (BQ3), berkaitan dengan penempatan armada dan layanan pembayaran. Insight karakteristik perjalanan (BQ2) dan struktur tarif (BQ5) ditempatkan

terakhir karena berkaitan dengan kebijakan jangka panjang, seperti spesifikasi armada dan evaluasi tarif.

5.2 Rekomendasi (7b)

Berdasarkan *insight* prioritas yang telah diidentifikasi dari hasil analisis eksploratif data perjalanan taksi kuning, disusun empat rekomendasi strategis untuk membantu manajemen transportasi kota dalam meningkatkan efisiensi operasional dan kualitas layanan. Setiap rekomendasi dirancang secara konkret agar memiliki dasar temuan data yang jelas serta dapat ditindaklanjuti secara langsung di lapangan. Rincian rekomendasi, tindakan konkret, dasar *insight*, serta bukti pendukungnya ditampilkan pada *Tabel 21*.

Tabel 21 Rekomendasi bagi Manajemen Transportasi Kota

Rekomendasi	Tindakan konkret	Dasar insight	Bukti / sumber
Penyesuaian jumlah armada secara dinamis berdasarkan waktu	Menambah armada di Manhattan pada pukul 17:00–19:00 hari kerja dan pada malam akhir pekan (00:00–02:00); mengurangi armada pada pukul 03:00–05:00	Insight 1	Puncak pukul 18:00 (693.915) vs terendah pukul 04:00 (88.524); Gambar *2*, Gambar *3*
Optimalisasi layanan di bandara JFK	Menyediakan zona penjemputan khusus (dedicated pickup zone) dan antrean taksi yang tertata di Bandara JFK	Insight 2	JFK peringkat ke-4 (400.458 penjemputan); median jarak Queens 10,02 mil; *Gambar 9*, *Tabel 17*
Penguatan layanan Flex Fare di luar Manhattan	Bekerja sama dengan penyedia aplikasi untuk memperluas jangkauan Flex Fare di Brooklyn, Bronx, dan Staten Island	Insight 3	Flex Fare mencakup 65,3% transaksi di Brooklyn, 47,1% di Bronx, dan 81,0% di Staten Island; *Tabel 16*
Evaluasi spesifikasi armada dan struktur tarif perjalanan pendek	Mempertimbangkan penggunaan kendaraan listrik atau kompak yang hemat energi untuk rute pendek perorangan, serta meninjau tarif dasar (base fare)	Insight 4 dan 5	Median jarak 1,90 mil; 83,21% penumpang tunggal; median tarif per mil rute < 1 mil mencapai 11,07 USD; Gambar 6, Gambar *12*, Tabel 18

Setiap rekomendasi pada Tabel 21 dapat ditelusuri kembali ke business question, data, dan hasil analisis. Sebagai contoh, rekomendasi penyesuaian jumlah armada berasal dari BQ1, yang dijawab menggunakan atribut tpep_pickup_datetime. Atribut ini diolah menjadi jam dan hari penjemputan, lalu

dianalisis melalui agregasi jumlah perjalanan (Gambar 2–4). Hasilnya menunjukkan puncak pada pukul 18:00 (693.915 perjalanan) dan titik terendah pada pukul 04:00 (88.524 perjalanan), sehingga armada perlu ditambah pada jam sibuk dan dikurangi pada dini hari kerja. Pola yang sama berlaku pada rekomendasi lainnya. Optimalisasi layanan bandara berasal dari BQ4 (PULocationID dan Taxi Zone Lookup), penguatan Flex Fare berasal dari BQ3 (payment_type per borough), dan evaluasi armada serta tarif berasal dari BQ2 dan BQ5 (trip_distance, passenger_count, dan fare_amount).

5.3 Keterbatasan Dataset dan Analisis (7c)

Laporan ini memiliki beberapa keterbatasan pada dataset dan cakupan analisis. Pertama, tip pada pembayaran tunai tidak tercatat dalam data (NYC TLC, 2026b), sehingga analisis persentase tip hanya mencakup transaksi kartu kredit. Kedua, terdapat *missing value* sistematis pada lima atribut untuk seluruh perjalanan *Flex Fare* (27,60% record), sehingga jumlah penumpang dan biaya tambahan tidak dapat dianalisis secara menyeluruh pada jenis perjalanan tersebut. Ketiga, periode analisis hanya mencakup tiga bulan (Januari–Maret 2026), sehingga belum menggambarkan pola musiman (*seasonality*) sepanjang tahun. Keempat, setelah proses *cleaning* masih terdapat nilai ekstrem pada tarif per mil (maksimum 62.370 USD) akibat jarak tempuh yang sangat pendek, sehingga analisis tarif menggunakan median karena rata-rata mudah terpengaruh nilai ekstrem. Kelima, analisis bersifat deskriptif dan korelasional, sehingga belum dapat membuktikan hubungan sebab-akibat, misalnya pengaruh jenis rute terhadap kecepatan, karena data tidak memuat informasi rute perjalanan.

5.4 Kesimpulan

Pengolahan Big Data pada dataset *NYC TLC Yellow Taxi Trip Records* periode Januari–Maret 2026 berukuran lebih dari 11 juta baris berhasil memberikan gambaran komprehensif mengenai pola operasional taksi kota. Hasil analisis menunjukkan bahwa variabel waktu, lokasi, dan metode pembayaran berkaitan erat dengan terhadap tingkat kepadatan, struktur tarif, dan pendapatan taksi. Implementasi rekomendasi penyesuaian armada dinamis dan pemerataan layanan digital berbasis aplikasi diharapkan dapat meningkatkan efisiensi operasional, meningkatkan efisiensi penempatan armada, serta memberikan peningkatan kualitas layanan transportasi publik di New York City.

DAFTAR PUSTAKA

Armbrust, M., Ghodsi, A., Xin, R., & Zaharia, M. (2021). Lakehouse: A new generation of open platforms that unify data warehousing and advanced analytics. *CIDR*.

Belov, V., & Nikulchev, E. (2021). Analysis of big data storage tools for data lakes based on Apache Hadoop platform. *Article in International Journal of Advanced Computer Science and Applications*, *12*(8), 2021. https://doi.org/10.14569/IJACSA.2021.0120864

Candra, A. P. (2025). Analisis Data Menggunakan Python: Memperkenalkan Pandas dan NumPy. *Journal of Information System and Education Development*, *3*(1), 11–16. https://doi.org/10.62386/jised.v3i1.118

Dean, J., & Ghemawat, S. (2008). MapReduce: Simplified data processing on large clusters. *Communications of the ACM*, *51*(1), 107–113. https://doi.org/10.1145/1327452.1327492

Hedayati, S., Maleki, N., Olsson, T., Ahlgren, F., Seyednezhad, M., & Berahmand, K. (2023). MapReduce scheduling algorithms in Hadoop: a systematic study. *Journal of Cloud Computing*, *12*(1). https://doi.org/10.1186/s13677-023-00520-9

Ketu, S., Mishra, P. K., & Agarwal, S. (2020). Performance Analysis of Distributed Computing Frameworks for Big Data Analytics: Hadoop Vs Spark. *Computacion y Sistemas*, *24*(2), 669–686. https://doi.org/10.13053/CyS-24-2-3401

Martinez, I., Viles, E., & G. Olaizola, I. (2021). Data Science Methodologies: Current Challenges and Future Approaches. *Big Data Research*, *24*. https://doi.org/10.1016/j.bdr.2020.100183

Mukaka, M. M. (2012). A guide to appropriate use of correlation coefficient in medical research. *Malawi Medical Journal*, *24*(3), 69–71.

Naumann, F. (2013). Data profiling revisited. *SIGMOD Record*, *42*(4), 40–49. https://doi.org/10.1145/2590989.2590995

NYC TLC. (2026a). *2025 annual report*. https://www.nyc.gov/assets/tlc/downloads/pdf/annual_report_2025.pdf

NYC TLC. (2026b). *TLC trip record data*. NYC.Gov. https://www.nyc.gov/site/tlc/about/tlc-trip-record-data.page

Oussous, A., Benjelloun, F. Z., Ait Lahcen, A., & Belfkih, S. (2018). Big Data technologies: A

survey. *Journal of King Saud University - Computer and Information Sciences*, *30*(4), 431–448. https://doi.org/10.1016/j.jksuci.2017.06.001

Prasetya, M. R. A., Priyatno, A. M., & Nurhaeni. (2023). Penanganan Imputasi Missing Values pada Data Time Series dengan Menggunakan Metode Data Mining. *Jurnal Informasi Dan Teknologi*, *5*(2), 52–62. https://doi.org/10.37034/jidt.v5i2.324

Ridzuan, F., & Wan Zainon, W. M. N. (2019). A review on data cleansing methods for big data. *Procedia Computer Science*, *161*, 731–738. https://doi.org/10.1016/j.procs.2019.11.177

Sastya, N. C., & Nugraha, I. (2023). Penerapan Metode CRISP-DM dalam Menganalisis Data untuk Menentukan Customer Behavior di MeatSolution. *Unistek*, *10*(2), 103–115. https://doi.org/10.33592/unistek.v10i2.3079

Sivarajah, U., Kamal, M. M., Irani, Z., & Weerakkody, V. (2017). Critical analysis of Big Data challenges and analytical methods. *Journal of Business Research*, *70*, 263–286. https://doi.org/10.1016/j.jbusres.2016.08.001

Verdonck, T., Baesens, B., Óskarsdóttir, M., & vanden Broucke, S. (2024). Special issue on feature engineering editorial. *Machine Learning*, *113*(7), 3917–3928. https://doi.org/10.1007/s10994-021-06042-2

Widianti, A., & Pratama, I. (2024). Penanganan Missing Values Dan Prediksi Data Timbunan Sampah Berbasis Machine Learning. *Rabit : Jurnal Teknologi Dan Sistem Informasi Univrab*, *9*(2), 242–251. https://doi.org/10.36341/rabit.v9i2.4789

Zaharia, M., Xin, R. S., Wendell, P., Das, T., Armbrust, M., Dave, A., Meng, X., Rosen, J., Venkataraman, S., Franklin, M. J., Ghodsi, A., Gonzalez, J., Shenker, S., & Stoica, I. (2016). Apache spark: A unified engine for big data processing. *Communications of the ACM*, *59*(11), 56–65. https://doi.org/10.1145/2934664

LAMPIRAN

Lampiran A. Tabel Pendukung

Tabel 22 Jumlah Nilai Kosong pada Seluruh Atribut

Atribut	Jumlah nilai kosong	Persentase (%)
passenger_count	3.057.123	27,60
congestion_surcharge	3.057.123	27,60
store_and_fwd_flag	3.057.123	27,60
RatecodeID	3.057.123	27,60
Airport_fee	3.057.123	27,60
tpep_dropoff_datetime	0	0
VendorID	0	0
tpep_pickup_datetime	0	0
DOLocationID	0	0
payment_type	0	0
trip_distance	0	0
PULocationID	0	0
extra	0	0
fare_amount	0	0
mta_tax	0	0
tip_amount	0	0
improvement_surcharge	0	0
tolls_amount	0	0
total_amount	0	0
cbd_congestion_fee	0	0

Tabel 23 Karakteristik Big Data pada Dataset

Karakteristik	Bukti dari dataset	Penjelasan
Volume	11.077.206 record, 20 atribut, ±181,9 MB (Parquet terkompresi); melebihi batas Excel 1.048.576 baris	Jumlah data yang sangat besar ini menyebabkan tidak bisa diolah menggunakan Microsoft Excel sehingga pengolahan menggunakan Python dan Pandas di Google Colab.
Velocity	±123.080 perjalanan per hari (11.077.206 ÷ 90 hari); TLC merilis data baru setiap bulan	Data terus bertambah per hari dengan rata-rata ±123.080 dan dirilis TLC setiap bulan, sehingga proses pengolahan data perlu dibuat otomatis dan dapat diulang setiap ada data bulan baru. Karena data dirilis perbulan, analisis dilakukan secara batch bukan real-time.
Variety	Tipe data beragam: tanggal-waktu, bilangan bulat, desimal, dan teks; berasal dari 2 sumber dengan format berbeda (Parquet dan CSV Taxi Zone Lookup)	Perbedaan tipe dan sumber data membuat analisis menjadi lebih kompleks, sehingga data perjalanan perlu digabungkan (*join*) dengan Taxi Zone Lookup berdasarkan LocationID untuk memperoleh nama zona dan *borough*. Selain itu, tipe data setiap atribut perlu dipastikan sesuai, misalnya kolom waktu bertipe *datetime* agar durasi perjalanan dapat dihitung.
Veracity	3.057.123 record (27,6%) kosong pada 5 atribut, seluruhnya perjalanan	Adanya nilai kosong dan nilai tidak logis menunjukkan bahwa data belum akurat sehingga belum siap untuk dianalisis.

	Flex Fare (`payment_type` = 0); 86.908 tarif negatif (0,78%); 370.198 jarak 0 mil (3,34%); 40.638 penumpang 0 (0,37%)	Nilai kosong ditemukan 3.057.123 *record* pada perjalanan dengan jenis Flex Fare, yaitu perjalanan yang dipesan lewat aplikasi dengan tarif yang ditetapkan diawal. Tahapan yang harus dilakukan data menggunakan Data Cleaning sebelum analisis dilakukan.
Value	Atribut waktu, lokasi, jarak, dan pembayaran dapat menjawab BQ1–BQ5	Data ini bernilai bagi manajemen transportasi karena atribut waktu, lokasi, jarak dan pembayaran di dalamnya dapat menjawab BQ1-BQ5, sehingga bisa menjadi dasar untuk mengambil keputusan seperti pengaturan jumlah armada pada jam sibuk, evaluasi tarif taksi, dan layanan pembayaran.

Tabel 24 Indikator Analitik

Indikator	Cara menghitung	Menjawab BQ	Kegunaan bagi pengelola
Jumlah perjalanan per jam dan per hari	Hitung jumlah record berdasarkan jam dan hari dari tpep_pickup_datetime	BQ1	Menentukan jumlah armada pada jam sibuk.
Rata-rata jarak tempuh, dan rata-rata durasi	Jarak: jumlah trip_distance ÷ jumlah perjalanan. Durasi: selisih dropoff − pickup dalam menit, lalu dirata-rata.	BQ2	memperkirakan waktu tempuh untuk penumpang
Persentase perjalanan berdasarkan metode pembayaran	Jumlah perjalanan tiap payment_type ÷ total perjalanan × 100%	BQ3	menyesuaikan layanan pembayaran
Jumlah penjemputan dan pengantaran per zona dan *borough*	Hitung jumlah record per PULocationID dan DOLocationID, lalu gabungkan dengan Taxi Zone Lookup	BQ4	memprioritaskan zona untuk penambahan armada
Persentase tip terhadap tarif per metode pembayaran.	tip_amount ÷ fare_amount × 100% (khusus pembayaran kartu kredit, karena tip tunai tidak tercatat.)	BQ5	menilai kepuasan penumpang per metode baya
Perbandingan rata-rata perjalanan per hari: hari kerja vs akhir pekan	Total perjalanan *weekday* ÷ jumlah hari *weekday*, dibandingkan dengan total *weekend* ÷ jumlah hari *weekend*	BQ1	menyesuaikan jadwal operasional armada antara hari kerja dan akhir pekan

Rata-rata kecepatan perjalanan (mil/jam)	trip_distance ÷ durasi (jam)	BQ2	mendeteksi perjalanan tidak wajar
Rata-rata tarif per mil (*fare per mile*)	fare_amount ÷ trip_distance	BQ5	mengevaluasi kewajaran tarif untuk perjalanan pendek dan panjang
Koefisien korelasi jarak, durasi, tarif, dan tip	Korelasi Pearson antara variabel numerik	BQ5	mengetahui faktor yang paling memengaruhi tarif sebagai dasar kebijakan tarif
Persentase perjalanan Flex Fare	Jumlah `payment_type` = 0 ÷ total perjalanan × 100%	BQ3	mengevaluasi kebijakan tarif di muka

Tabel 25 Atribut yang Digunakan dan Perannya dalam Analisis

Atribut	Tipe data	Deskripsi	Peran dalam analisis	BQ
tpep_pickup_datetime	datetime	Waktu argo dinyalakan	Menentukan jam dan hari dengan jumlah perjalanan tertinggi (BQ1); dipasangkan dengan tpep_dropoff_datetime untuk menghitung durasi perjalanan (BQ2); serta melihat pola metode pembayaran berdasarkan waktu (BQ3).	BQ1, BQ2, BQ3
tpep_dropoff_datetime	datetime	Waktu argo dimatikan	dikombinasikan dengan atribut tpep_pickup_datetime untuk menghitung durasi perjalanan (BQ2)	BQ2
PULocationID	integer	ID zona penjemputan	Di-*join* dengan Taxi Zone Lookup untuk menentukan zona dan *borough* penjemputan dengan jumlah perjalanan tertinggi (BQ4); dikombinasikan dengan payment_type untuk melihat pola metode pembayaran berdasarkan lokasi (BQ3).	BQ3, BQ4
DOLocationID	integer	ID zona pengantaran	Di-*join* dengan Taxi Zone Lookup untuk menentukan zona dan *borough* pengantaran dengan jumlah perjalanan tertinggi (BQ4).	BQ4
trip_distance	float	Jarak tempuh (mil)	Menganalisis karakteristik perjalanan (BQ2); dibandingkan dengan fare_amount untuk melihat hubungan jarak dan tarif (BQ5).	BQ2, BQ5
passenger_count	float	Jumlah penumpang	untuk melihat jumlah penumpang (BQ2) tetapi ada masalah karena memiliki nilai kosong pada atribut ini.	BQ2
payment_type	integer	Kode metode pembayaran	untuk melihat metode pembayaran yang paling sering dipakai (BQ3); dikombinasikan dengan tip_amount untuk membandingkan persentase tip antar metode pembayaran (BQ5).	BQ3, BQ5
fare_amount	float	Tarif argo (USD)	Menganalisis tarif berdasarkan jarak dan waktu serta menghitung tarif per mil (BQ5).	BQ5
tip_amount	float	Tip, hanya kartu kredit (USD)	Dibagi dengan fare_amount untuk menghasilkan persentase tip (BQ5); hanya mencatat tip dari pembayaran kartu kredit.	BQ5
total_amount	float	Total yang dibayar penumpang (USD)	Menggambarkan total biaya yang dibayar penumpang per perjalanan (BQ5).	BQ5

Masalah	Jumlah terdampak (profiling)	Record dihapus	Tindakan	Alasan
Tahap 1				
Pickup di luar Jan–Mar 2026	10	10	Hapus	Waktu tidak sesuai periode analisis (ada yang tercatat tahun 2008)
Durasi ≤ 0 menit	134.801	134.801	Hapus	Waktu turun sama dengan atau sebelum waktu naik, sehingga tidak mungkin terjadi
Durasi > 180 menit	4.464	4.463	Hapus	Tidak wajar untuk taksi dalam kota (maksimum ±6,4 hari)
Tarif ≤ 0	94.364	94.221	Hapus	Bukan perjalanan normal; diduga transaksi pembatalan atau pengembalian dana
Total bayar negatif	88.580	0*	Hapus	Bukan perjalanan normal; diduga transaksi pembatalan atau pengembalian dana
Tip negatif	148	0*	Hapus	Tip tidak mungkin bernilai negatif
Jarak = 0 mil	370.198	358.050	Hapus	Diduga perjalanan batal; tarif per mil tidak dapat dihitung
Jarak > 100 mil	495	442	Hapus	Tidak wajar untuk taksi dalam kota (maksimum 328.522 mil)
Penumpang > 6	14	3	Hapus	Melebihi kapasitas taksi
Tahap 2				
Durasi < 1 menit	31.169	31.169	Hapus	Terlalu singkat untuk perjalanan nyata; membuat kecepatan tidak wajar
Kecepatan > 80 mil/jam	2.331	1.254	Hapus	Tidak mungkin dicapai di dalam kota
Perbaikan nilai				
Penumpang = 0	40.638	0	Diubah menjadi NaN (38.470)	Hanya kolom penumpang yang salah; atribut lain tetap berguna
Persentase tip > 100%	9.800	0	Diubah menjadi NaN (9.419)	Nilai ekstrem dikecualikan dari analisis tip tanpa menghapus perjalanan
Flex Fare (5 atribut kosong)	3.057.123	0	Dipertahankan + penanda (2.778.321)	Atribut waktu, lokasi, jarak, dan tarif lengkap; menghapusnya membuang 27,6% data
Total dihapus		624.413		

Tabel 26 Aturan Data Cleaning

Lampiran B.
Kode Program (Notebook)

Link COLAB (Sharing) :
https://colab.research.google.com/drive/1yHrRVo3FsC11HKq3kQjsvdYUeEy8eTBy?usp=sharing

Bagian notebook	Isi	Subbab terkait
Setup & pemuatan data	Mount Drive, membaca 3 file Parquet	2.4
Data profiling	Missing value, duplikat, nilai tidak logis, outlier	3.1
Pipeline cleaning & feature engineering	Cleaning 2 tahap, 7 fitur, join zona	3.2–3.3
EDA	Statistik deskriptif, 13 visualisasi, korelasi	4.1–4.3

Lampiran C.
AI Usage Declaration

Tools AI yang digunakan: Claude (Anthropic).

Bagian laporan	Bentuk bantuan AI	Dikerjakan penulis
Latar belakang	Contoh paragraf pertama, kalimat pembuka, perbaikan dan peringkasan bahasa	Draf paragraf 2–4, data Tabel 1
Bab 1	Struktur, contoh BQ1, pilihan arah tujuan dan indikator, perbaikan bahasa	Draf tujuan, BQ2–BQ5, penjelasan 5V, kegunaan indikator
Bab 2	Penjelasan konsep lifecycle dan format data, tabel perbandingan format, diagram arsitektur *Gambar 1*, perbaikan bahasa 2.5	Data understanding, peran atribut, pemilihan lakehouse
Bab 3	Kode profiling, cleaning, dan feature engineering; usulan aturan cleaning; kolom alasan *Tabel 26* Aturan Data Cleaning	Menjalankan kode, memutuskan aturan, interpretasi hasil
Bab 4	Kode EDA dan visualisasi, kerangka interpretasi, *Tabel 19* berdasarkan angka hasil analisis	Interpretasi grafik dan korelasi
Bab 5	Koreksi angka, perbaikan bahasa *Tabel 20* dan *Tabel 21*	Pemilihan insight, rekomendasi, keterbatasan
Lainnya	*Debugging* Google Colab, saran struktur , referensi, pengecekan konsistensi angka, sitasi, dan penulisan laporan	Verifikasi referensi dan seluruh angka

Tabel 27 AI Usage Declaration

Seluruh hasil akhir telah diperiksa dan dapat dipertanggungjawabkan oleh penulis.

Lampiran D.
Individual Contribution Statement

Nama / NIM	Bagian yang dikerjakan	Kontribusi teknis	Persentase
Callysta Elysia Theona Dethan / 825240012	Seluruh laporan (Pendahuluan, Bab 1–5)	Akuisisi data, pengolahan di Google Colab (profiling, cleaning, feature engineering, EDA), visualisasi, penulisan laporan	100%

Tabel 28 *Individual Contribution Statement*